

Previsao do Fechamento do IBOVESPA

Tech Challenge - Fase 2 - POSTECH Data Analytics

Estrategia de dados, storytelling e modelo preditivo de series temporais

Este documento descreve, passo a passo, a estrategia de dados construida para prever o fechamento diario do indice IBOVESPA, incluindo a explicacao de cada etapa do codigo desenvolvido, as decisoes tecnicas tomadas e os resultados obtidos. O codigo completo e executavel esta disponivel no notebook Jupyter que acompanha esta entrega.

Nome: Renan Cotrin Lapastina

RM: 366292

Resumo executivo

A entrega trata o problema como serie temporal e regressao. A assertividade principal e calculada como $100 * (1 - WMAPE)$, conforme orientacao recebida para uso de metricas de distancia.

Sumario

1. Escopo analítico e criterio de sucesso	3
1.1 Aderencia ao enunciado	3
1.2 Como a entrega esta organizada	4
2. Preparacao da base historica	5
3. Leitura historica do IBOVESPA	6
3.1 Ciclos economicos observados	6
3.2 Retornos, choques e faixa de tolerancia	7
4. Diagnostico estatistico da serie	8
4.1 Decomposicao da serie.....	8
4.2 Estacionariedade pelo teste ADF.....	9
4.3 Memoria curta pela ACF e PACF	9
5. Construcao de alvos e atributos	10
6. Validacao fora da amostra	11
7. Experimentos e escolha do modelo	12
7.4 Resultado comparativo.....	13
7.6 Robustez da tolerancia de erro	16
8. Investigacao complementar de direcao	18
9. Projecao dos proximos 15 pregoes.....	19
10. Fechamento tecnico.....	21

1. Escopo analítico e critério de sucesso

O desafio foi construir um modelo preditivo de séries temporais para o fechamento diário do IBOVESPA, com assertividade mínima de 80% e uso como ferramenta acadêmica de apoio à decisão. Antes de escolher modelos, foi necessário definir o que significa acertar uma previsão em uma série financeira.

O fechamento de um índice amplo costuma ficar muito próximo do fechamento anterior. Por isso, uma previsão numérica pode apresentar erro percentual baixo mesmo quando o mercado continua difícil de antecipar. A estratégia adotada separa duas perguntas: prever o valor de fechamento, que é a entrega formal por regressão, e investigar a direção do próximo pregão como análise complementar.

- Regressão: prever o fechamento do próximo pregão e avaliar com WMAPE, MAE, assertividade por 1 - WMAPE e acerto dentro de uma faixa de tolerância.
- Classificação: avaliar alta ou baixa como investigação paralela, sem forçar uma acurácia artificial em uma tarefa naturalmente mais instável.

Decisão metodológica

A meta formal é defendida pela regressão, com validação temporal correta. A classificação entra como transparência técnica sobre os limites reais do problema.

1.1 Aderência ao enunciado

Exigência da prova	Como foi atendida
Modelo de série temporal	ARIMA(5,1,0) com validação walk-forward e comparação contra baseline.
Assertividade mínima de 80%	99,07% por 1 - WMAPE e 92,00% dentro da faixa de 2,15%.
Storytelling dos picos	Linha do tempo econômica e leitura dos choques de volatilidade.
Explicação e vantagens do modelo	ADF, ACF/PACF, vantagens do ARIMA e comparação com modelos alternativos.
Previsão de 15 dias	Tabela e gráfico de 30/07/2026 a 19/08/2026 com intervalo de confiança.

1.2 Como a entrega esta organizada

- Leitura, limpeza e padronizacao da base historica.
- Storytelling exploratorio e contexto economico dos ciclos do IBOVESPA.
- Decomposicao da serie, teste ADF e leitura de ACF/PACF.
- Engenharia de atributos para modelos complementares.
- Separacao treino/teste respeitando a ordem temporal.
- Baseline de persistencia, ARIMA estatico e ARIMA walk-forward.
- Comparacao de resultados por WMAPE, MAE e tolerancia de erro.
- Predicao dos proximos 15 pregos e conclusao com limitacoes.

2. Preparacao da base historica

A base utilizada contem o historico diario do IBOVESPA obtido no Investing.com, com data, fechamento, abertura, maxima, minima, volume negociado e variacao percentual. O arquivo original vem em ordem decrescente, do pregao mais recente para o mais antigo, e usa formato brasileiro nos numeros.

A etapa de limpeza foi tratada com cuidado porque valores como 175.831 representam 175.831 pontos, nao 175,831 pontos. Por isso, a leitura inicial preserva tudo como texto e a conversao numerica acontece de forma controlada.

Indicador	Valor
Periodo bruto	2010-01-04 a 2026-07-29
Quantidade de pregoes	4.110
Colunas originais	7
Fonte	Investing.com - historico diario do IBOVESPA

2.1 Regras de limpeza implementadas

- Conversao da coluna de data para tipo datetime e reordenacao cronologica.
- Conversao de fechamento, abertura, maxima e minima do formato brasileiro para numero.
- Conversao da variacao percentual removendo o simbolo de porcentagem e respeitando virgula decimal.
- Padronizacao do volume negociado, que mistura unidades K, M e B no export do Investing.com.
- Normalizacao dos nomes de colunas para evitar problemas com acentos em diferentes ambientes.

```
raw_df = load_raw_data()
dados = clean_ibovespa_data(raw_df)

cleaned["data"] = pd.to_datetime(cleaned["data"], format="%d.%m.%Y")
cleaned = cleaned.sort_values("data").reset_index(drop=True)

for column in ["fechamento", "abertura", "maxima", "minima"]:
    cleaned[column] = cleaned[column].apply(parse_brazilian_number)
```

O volume recebeu uma funcao propria porque a fonte alterna unidades no mesmo campo. Sem esse cuidado, valores em milhoes e bilhoes poderiam ser comparados como se estivessem na mesma escala, distorcendo qualquer atributo derivado de liquidez.

3. Leitura historica do IBOVESPA

Com os dados limpos, a primeira leitura foi visual: antes de propor modelos, e preciso entender o comportamento historico do indice. A serie do IBOVESPA nao apresenta um padrao sazonal simples; ela e marcada por ciclos longos, choques macroeconomicos e mudancas de regime.



Figura 1 - Evolucao historica do fechamento do IBOVESPA.

3.1 Ciclos economicos observados

A leitura de negocio foi organizada em periodos. Essa etapa e importante porque transforma o grafico em storytelling: cada movimento relevante da serie passa a ser conectado a um contexto economico e politico plausivel.

Periodo	Comportamento	Contexto
2010-2015	Queda / estagnacao	Desaceleracao economica, deterioracao fiscal e perda de confianca do mercado.
2015-2016	Ponto de minimo	Crise politica, impeachment e recessao economica elevaram a aversao a risco.
2016-2020	Ciclo de alta	Expectativa de reformas, juros globais baixos e retomada gradual do fluxo para risco.
Fev-Mar/2020	Choque abrupto	Pandemia de Covid-19, circuit breakers e repricing global de ativos.
2020-2021	Recuperacao em V	Estimulos monetarios/fiscais e Selic em patamar historicamente baixo.

2021-2022	Lateralizacao / queda	Aperto monetario para conter inflacao e aumento da incerteza eleitoral.
2023-2026	Novo ciclo de alta	Ciclo de corte de juros, resultados corporativos e renovacao de recordes do indice.

Esse pano de fundo reforca que o IBOVESPA precisa ser reavaliado periodicamente: o comportamento estatistico do indice muda quando o ambiente de juros, risco politico, fluxo estrangeiro e resultados corporativos tambem muda.

3.2 Retornos, choques e faixa de tolerancia

A variacao diaria mostra que a maior parte dos pregoes se concentra em movimentos pequenos, enquanto choques extremos aparecem em momentos especificos, especialmente em 2020. Essa distribuicao justifica usar uma metrica de tolerancia alem do WMAPE.




Figura 2 - Retornos diarios e distribuicao da variacao percentual.

Faixa operacional

A media de variacao absoluta diaria ficou proxima de 1,04%, enquanto o percentil 90 ficou perto de 2,20%. Por isso, a faixa de 2,15% foi usada como criterio pratico de acerto alem do WMAPE.

4. Diagnostico estatístico da serie

4.1 Separacao entre tendencia, sazonalidade e residuo

Para decompor a serie em tendencia, sazonalidade e residuo, a serie foi reorganizada em frequencia diaria e preenchida com o ultimo fechamento conhecido apenas para fins visuais. Os modelos preditivos continuam usando os dias reais de pregao.




Figura 3 - Decomposicao da serie de fechamento.

A decomposicao mostra que a tendencia explica a maior parte do movimento historico. A sazonalidade anual aparece com amplitude pequena, enquanto os residuos concentram choques nao explicados, principalmente em momentos de estresse de mercado.

4.2 Estacionariedade pelo teste ADF

O teste ADF foi usado para decidir a ordem de diferenciacao do ARIMA. A hipotese nula do teste e que a serie possui raiz unitaria, ou seja, nao e estacionaria.

Teste ADF	P-valor	Interpretacao
Serie original	0,9439	Nao estacionaria
Primeira diferenca	0,00000000	Estacionaria

Como a serie original nao e estacionaria e a primeira diferenca se torna estacionaria, a especificacao integrada $d=1$ e tecnicamente justificada.

4.3 Memoria curta pela ACF e PACF




Figura 4 - ACF e PACF usadas como apoio para escolha do ARIMA.

Os graficos de autocorrelacao indicam dependencia de curto prazo, sugerindo que os ultimos pregoes carregam informacao relevante para a previsao do proximo fechamento. Essa leitura sustenta o teste de um ARIMA com componente autorregressivo curto.

5. Construcao de alvos e atributos

Embora o ARIMA seja a entrega principal, tambem foram criados atributos tecnicos para modelos supervisionados de comparacao. Todos os atributos usam apenas informacao disponivel ate o dia da previsao, evitando vazamento de dados.

- Retornos acumulados e defasados em janelas curtas.
- Medias moveis e distancia do fechamento em relacao as medias.
- Volatilidade recente, amplitude intradiaria e corpo do candle.
- Posicao do fechamento em janelas recentes.
- Indicadores tecnicos como RSI, MACD e Bandas de Bollinger.
- Variaveis simples de calendario, como dia da semana e mes.

Indicador	Valor
Base com features	4.055 registros
Inicio da base modelavel	2010-03-17
Fim da base modelavel	2026-07-28
Proporcao historica de altas	51,20%

```
featured["fechamento_amanha"] = featured["fechamento"].shift(-1)
featured["alta_amanha"] = (
    featured["fechamento_amanha"] > featured["fechamento"]
).astype(int)
```

```
featured["retorno_5d"] = featured["fechamento"].pct_change(5)
featured["media_movel_21"] = featured["fechamento"].rolling(21).mean()
featured["volatilidade_21d"] = featured["retorno_1d"].rolling(21).std()
```

O ponto central dessa etapa e que o alvo sempre olha para o proximo pregao, enquanto as features olham apenas para tras. Essa separacao reduz o risco de lookahead bias e deixa a avaliacao mais parecida com o uso real: ao final do dia D, o modelo tenta estimar D+1.

6. Validacao fora da amostra

Para evitar vazamento de informacao futura, a divisao entre treino e teste foi feita de forma temporal. A linha preditora de 28/07/2026 usa somente informacoes conhecidas ate essa data e tem como alvo o fechamento de 29/07/2026. Assim, o teste cobre 125 datas-alvo, de 28/01/2026 a 29/07/2026.

Conjunto	Registros	Datas-alvo
Treino	3.984	2010-01-05 a 2026-01-27
Teste	125	2026-01-28 a 2026-07-29

```
def temporal_split(dataset, test_size=125):  
    train = dataset.iloc[:-test_size].copy()  
    test = dataset.iloc[-test_size:].copy()  
    return train, test
```

Validacao temporal

Nao houve embaralhamento aleatorio. O modelo foi treinado no passado e avaliado no periodo mais recente com alvo conhecido, simulando melhor uma situacao real de previsao.

7. Experimentos e escolha do modelo

Foram comparados tres caminhos: baseline de persistencia, ARIMA estatico e ARIMA walk-forward. A persistencia usa o fechamento de hoje como previsao para amanha; o ARIMA estatico treina uma vez; o walk-forward recalibra o historico a cada novo ponto observado no teste.

A funcao de avaliacao concentra as metricas principais. O WMAPE foi escolhido por medir erro percentual ponderado pelo tamanho real da serie; em seguida, a assertividade e calculada por $1 - \text{WMAPE}$, conforme orientacao recebida para metricas de distancia.

```
def wmape(y_true, y_pred):  
    actual = np.asarray(y_true, dtype=float)  
    predicted = np.asarray(y_pred, dtype=float)  
    return np.sum(np.abs(actual - predicted)) / np.sum(np.abs(actual))  
  
assertiveness = 1 - wmape(y_true, y_pred)
```

7.1 Referencia ingenua: fechamento de hoje

O primeiro modelo testado foi o baseline Naive, ou persistencia: a previsao para amanha e simplesmente o fechamento de hoje. Em series financeiras de alta liquidez, esse baseline costuma ser muito competitivo em erro percentual, justamente porque a variacao diaria tende a ser pequena.

```
naive_pred = test_reg["fechamento"].values  
naive_result = evaluate_predictions(  
    "Naive - persistencia",  
    y_true,  
    naive_pred,  
)
```

Metrica do baseline	Resultado	Leitura
WMAPE	0,93%	Erro percentual ponderado muito baixo.
Assertividade	99,07%	Acima da meta, mas baseada em regra ingenua.
MAE	1.678 pontos	Erro medio absoluto em pontos do indice.
Acerto 2,15%	91,20%	Referencia operacional para comparar modelos.

Esse baseline nao deve ser ignorado. Ele funciona como referencia minima: qualquer modelo mais sofisticado precisa ser comparado contra ele para que o resultado nao pareca melhor do que realmente e. Ao mesmo tempo, ele nao oferece estrutura estatistica, intervalo de confianca nem explicacao de comportamento da serie; ele apenas repete o ultimo fechamento conhecido.

7.2 Racional estatístico para o ARIMA

A escolha do ARIMA não foi feita apenas por tentativa e erro. O teste ADF mostrou que a série original não é estacionária, enquanto a primeira diferença se torna estacionária. Isso sustenta o termo integrado $d=1$. Os gráficos de ACF e PACF indicam dependência de curto prazo, coerente com uma especificação ARIMA simples e interpretável.

Vantagem	Por que importa neste projeto
Fundamentação estatística	A ordem do modelo é apoiada por ADF, ACF e PACF, tornando a decisão auditável.
Interpretabilidade	Os componentes autorregressivo e integrado são explicáveis para uma banca técnica.
Intervalo de confiança	A previsão traz faixa de incerteza, algo essencial em séries financeiras.
Baixo custo computacional	Funciona bem com uma única série histórica de cerca de 4 mil pregões.
Extensibilidade	Pode evoluir para SARIMAX com Selic, câmbio ou índices externos como variáveis exógenas.

7.3 Validação walk-forward

Na avaliação walk-forward, o modelo é recalibrado a cada passo com o fechamento real observado no período de teste. Isso aproxima a avaliação de um uso prático: no fim de cada pregão, o histórico é atualizado e uma nova previsão é gerada.

```
history = list(train["fechamento"].values)
predictions = []
for actual_close in test["fechamento"].values:
    history.append(actual_close)
    model = ARIMA(history, order=(5, 1, 0)).fit()
    predictions.append(float(model.forecast(steps=1)[0]))
```

7.4 Resultado comparativo

Modelo	WMAPE	Assertividade	MAE	Acerto 2,15%
ARIMA(5,1,0) walk-forward	0,93%	99,07%	1.681 pontos	92,00%

Naive - persistencia	0,93%	99,07%	1.678 pontos	91,20%
ARIMA(5,1,0) estatico	3,75%	96,25%	6.787 pontos	28,00%



Figura 5 - Fechamento real versus previsões no período de teste.




Figura 6 - Erro percentual do ARIMA walk-forward ao longo do período de teste.

Modelo escolhido

O ARIMA(5,1,0) walk-forward foi escolhido para a narrativa principal por respeitar a estrutura temporal e atingir 99,07% de assertividade por 1 - WMAPE, além de 92,00% de acerto dentro da faixa de 2,15%.

7.5 Regressao com atributos tecnicos

Como contraponto ao ARIMA, foram testados modelos de regressao supervisionada com os 37 atributos tecnicos construidos na etapa de engenharia. A ideia foi verificar se sinais de retorno, volatilidade, medias moveis, candle, volume e calendario melhorariam a previsao do fechamento seguinte.

```
lin_reg = Pipeline([
    ("scaler", StandardScaler()),
    ("model", LinearRegression()),
])
lin_reg.fit(x_train, y_train)
```

```
rf_reg = RandomForestRegressor(
    n_estimators=300,
    max_depth=6,
    min_samples_leaf=10,
    random_state=42,
)
rf_reg.fit(x_train, y_train)
```

Modelo com atributos	WMAPE	Assertividade	MAE	Acerto 2,15%
Linear Regression - features	0,95%	99,05%	1.712 pontos	91,20%
Random Forest - features	7,36%	92,64%	13.302 pontos	12,00%

A regressao linear fica competitiva porque o proprio fechamento atual esta entre as variaveis de entrada, fazendo o modelo aprender uma relacao muito proxima da persistencia. O Random Forest, por outro lado, perde aderencia neste recorte porque modelos baseados em arvores tendem a criar faixas de previsao e podem ter dificuldade para extrapolar suavemente o nivel atual do indice.

Por isso, os modelos com atributos entram como validacao adicional, nao como escolha final. Eles mostram que adicionar muitos indicadores tecnicos nao garante ganho real sobre uma serie financeira de curto prazo. O ARIMA walk-forward permanece como modelo principal por ser mais aderente ao enunciado de series temporais, ter fundamentacao estatistica pela estacionariedade/autocorrelacao e entregar intervalo de confianca para a previsao de 15 pregos.




Figura 7 - Comparacao entre ARIMA, baseline e regressoes com atributos pela tolerancia de 2,15%.

7.6 Robustez da tolerancia de erro

Como a leitura de acerto por tolerancia depende da margem escolhida, tambem foi feita uma analise de sensibilidade. Isso evita escolher uma unica faixa sem contexto e mostra como o modelo se comporta em margens mais conservadoras e mais flexiveis.

Tolerancia de erro	Acerto ARIMA walk-forward
1,00%	64,80%
1,50%	78,40%
2,00%	90,40%
2,15%	92,00%
2,50%	95,20%
3,00%	99,20%




Figura 8 - Distribuição do erro percentual absoluto do ARIMA walk-forward.




Figura 9 - Sensibilidade do acerto conforme a tolerancia de erro.

8. Investigacao complementar de direcao

Tambem foram testados modelos supervisionados com features tecnicas e classificacao de direcao. Essa frente foi mantida como complemento, pois a orientacao atual da prova favorece regressao e metricas de distancia. A classificacao de alta/baixa e naturalmente mais instavel, especialmente em dias com variacoes pequenas.

Essa decisao deixa a entrega mais honesta. Em vez de inflar uma acuracia de direcao por escolha oportunista de janela, threshold ou hiperparametro, o projeto reporta a regressao como resposta principal e a classificacao como investigacao dos limites do problema.

Leitura tecnica

Prever o valor aproximado do fechamento e diferente de prever corretamente a direcao diaria. A segunda tarefa e mais dura e tende a ficar perto de 50% quando usamos apenas informacoes publicas do proprio indice.

9. Projecao dos proximos 15 pregoes

Com a base atualizada ate 29/07/2026, a previsao inicia em 30/07/2026 e termina em 19/08/2026. O intervalo de confianca aumenta ao longo do horizonte, refletindo a incerteza acumulada.

Data	Previsto	IC 95% inf.	IC 95% sup.
30/07/2026	174.023	171.617	176.430
31/07/2026	173.911	170.598	177.225
03/08/2026	173.947	169.889	178.005
04/08/2026	173.946	169.258	178.634
05/08/2026	173.892	168.641	179.143
06/08/2026	173.897	168.117	179.677
07/08/2026	173.893	167.630	180.156
10/08/2026	173.894	167.182	180.606
11/08/2026	173.894	166.761	181.027
12/08/2026	173.893	166.362	181.423
13/08/2026	173.893	165.984	181.801
14/08/2026	173.893	165.623	182.162
17/08/2026	173.893	165.277	182.508
18/08/2026	173.893	164.945	182.840
19/08/2026	173.893	164.625	183.160



Figura 10 - Projecao dos proximos 15 pregos.

10. Fechamento tecnico

A solucao final atende ao objetivo da prova substitutiva por tratar o IBOVESPA como serie temporal, usar decomposicao e estacionariedade para justificar o ARIMA, avaliar previsao numerica com WMAPE e apresentar uma previsao de 15 pregoes com intervalo de confianca. O resultado principal supera a meta de 80% pela metrica de assertividade orientada por erro percentual.

10.1 Principais entregas

- Uma base historica atualizada e limpa do IBOVESPA ate 29/07/2026.
- Storytelling conectando ciclos do indice a eventos economicos relevantes.
- Decomposicao, teste ADF e leitura de autocorrelacao para justificar a abordagem temporal.
- Comparacao entre baseline, ARIMA estatico e ARIMA walk-forward.
- Previsao de 15 pregoes com intervalo de confianca.

10.2 Limites da abordagem e evolucoes

Uma assertividade alta por WMAPE nao significa prever perfeitamente o mercado. O proprio baseline de persistencia fica forte porque o IBOVESPA geralmente nao muda muitos pontos de um pregao para o outro. Por isso, a entrega combina WMAPE, MAE, tolerancia de erro e interpretacao economica, em vez de vender uma unica metrica como verdade absoluta.

A classificacao de direcao diaria segue mais dificil e instavel, o que e coerente com a literatura de mercados eficientes. Como proximo passo, o projeto poderia evoluir para SARIMAX, incorporando variaveis exogenas como Selic, cambio, juros futuros, S&P 500, commodities e indicadores de sentimento.

A interpretacao deve permanecer academica e analitica: o modelo nao substitui avaliacao de risco, eventos macroeconomicos ou analise de mercado em tempo real.