

Previsão do Fechamento do IBOVESPA

Tech Challenge - Fase 2 - POSTECH Data Analytics

Estratégia de dados, storytelling e modelo preditivo de séries temporais

Este documento descreve, passo a passo, a estratégia de dados construída para prever o fechamento diário do índice IBOVESPA, incluindo a explicação de cada etapa do código desenvolvido, as decisões técnicas tomadas e os resultados obtidos. O código completo e executável está disponível no notebook Jupyter que acompanha esta entrega.

Nome: Renan Cotrin Lapastina

RM: 366292

Resumo executivo

A entrega trata o problema como série temporal e regressão. A assertividade principal é calculada como $100 * (1 - WMAPE)$, conforme orientação recebida para uso de métricas de distância.

Sumário

1. Escopo analítico e criterio de sucesso	3
1.1 Aderência ao enunciado	3
1.2 Como a entrega esta organizada	4
2. Preparacao da base historica	5
2.1 Regras de limpeza implementadas	5
3. Leitura histórica do IBOVESPA	7
3.1 Ciclos economicos observados	7
3.2 Retornos, choques e faixa de tolerância	8
4. Diagnóstico estatístico da série	9
4.1 Separação entre tendência, sazonalidade e resíduo	9
4.2 Estacionariedade pelo teste ADF	9
4.3 Memoria curta pela ACF e PACF	10
5. Construção de alvos e atributos	11
6. Validação fora da amostra	12
7. Experimentos e escolha do modelo	13
7.1 Referência ingênua: fechamento de hoje	13
7.2 Racional estatístico para o ARIMA	14
7.3 Validacao walk-forward	15
7.4 Resultado comparativo	15
7.5 Regressão com atributos técnicos	16
7.6 Robustez da tolerância de erro	18
8. Investigação complementar de direção	20
9. Projeção dos próximos 15 pregões	21
10. Fechamento técnico	23
10.1 Principais entregas	23
10.2 Limites da abordagem e evoluções	23

1. Escopo analítico e critério de sucesso

O desafio foi construir um modelo preditivo de séries temporais para o fechamento diário do IBOVESPA, com assertividade mínima de 80% e uso como ferramenta acadêmica de apoio à decisão. Antes de escolher modelos, foi necessário definir o que significa acertar uma previsão em uma série financeira.

O fechamento de um índice amplo costuma ficar muito próximo do fechamento anterior. Por isso, uma previsão numérica pode apresentar erro percentual baixo mesmo quando o mercado continua difícil de antecipar. A estratégia adotada separa duas perguntas: prever o valor de fechamento, que é a entrega formal por regressão, e investigar a direção do próximo pregão como análise complementar.

- Regressão: prever o fechamento do próximo pregão e avaliar com WMAPE, MAE, assertividade por 1 - WMAPE e acerto dentro de uma faixa de tolerância.
- Classificação: avaliar alta ou baixa como investigação paralela, sem forçar uma acurácia artificial em uma tarefa naturalmente mais instável.

Decisão metodológica

A meta formal é defendida pela regressão, com validação temporal correta. A classificação entra como transparência técnica sobre os limites reais do problema.

1.1 Aderência ao enunciado

Exigencia da prova	Como foi atendida
Modelo de serie temporal	ARIMA(5,1,0) com validação walk-forward e comparação contra baseline.
Assertividade mínima de 80%	98,67% por 1 - WMAPE e 82,40% dentro da faixa de 2,15%.
Storytelling dos picos	Linha do tempo econômica e leitura dos choques de volatilidade.
Explicação e vantagens do modelo	ADF, ACF/PACF, vantagens do ARIMA e comparação com modelos alternativos.
Previsao de 15 dias	Tabela e gráfico de 23/07/2026 a 12/08/2026 com intervalo de confiança.

1.2 Como a entrega esta organizada

- Leitura, limpeza e padronização da base histórica.
- Storytelling exploratório e contexto econômico dos ciclos do IBOVESPA.
- Decomposição da série, teste ADF e leitura de ACF/PACF.
- Engenharia de atributos para modelos complementares.
- Separação treino/teste respeitando a ordem temporal.
- Baseline de persistencia, ARIMA estatico e ARIMA walk-forward.
- Comparação de resultados por WMAPE, MAE e tolerância de erro.
- Predição dos próximos 15 pregões e conclusão com limitações.

2. Preparacao da base historica

A base utilizada contém o histórico diário do IBOVESPA obtido no Investing.com, com data, fechamento, abertura, máxima, mínima, volume negociado e variação percentual. O arquivo original vem em ordem decrescente, do pregão mais recente para o mais antigo, e usa formato brasileiro nos números.

A etapa de limpeza foi tratada com cuidado porque valores como 175.831 representam 175.831 pontos, não 175,831 pontos. Por isso, a leitura inicial preserva tudo como texto e a conversão numérica acontece de forma controlada.

Indicador	Valor
Periodo bruto	2010-01-04 a 2026-07-22
Quantidade de pregões	4.105
Colunas originais	7
Fonte	Investing.com - historico diario do IBOVESPA

2.1 Regras de limpeza implementadas

- Conversão da coluna de data para tipo datetime e ordenação cronológica.
- Conversão de fechamento, abertura, máxima e mínima do formato brasileiro para número.
- Conversão da variação percentual removendo o símbolo de porcentagem e respeitando vírgula decimal.
- Padronização do volume negociado, que mistura unidades K, M e B no export do Investing.com.
- Normalização dos nomes de colunas para evitar problemas com acentos em diferentes ambientes.

```
raw_df = load_raw_data()
dados = clean_ibovespa_data(raw_df)

cleaned["data"] = pd.to_datetime(cleaned["data"], format="%d.%m.%Y")
cleaned = cleaned.sort_values("data").reset_index(drop=True)

for column in ["fechamento", "abertura", "maxima", "minima"]:
    cleaned[column] = cleaned[column].apply(parse_brazilian_number)
```

O volume recebeu uma função própria porque a fonte alterna unidades no mesmo campo. Sem esse cuidado, valores em milhões e milhões poderiam ser comparados como se estivessem na mesma escala, distorcendo qualquer atributo derivado de liquidez.

3. Leitura histórica do IBOVESPA

Com os dados limpos, a primeira leitura foi visual: antes de propor modelos, é preciso entender o comportamento histórico do índice. A série do IBOVESPA não apresenta um padrão sazonal simples; ela é marcada por ciclos longos, choques macroeconômicos e mudanças de regime.



Figura 1 - Evolução histórica do fechamento do IBOVESPA.

3.1 Ciclos economicos observados

A leitura de negócios foi organizada em períodos. Essa etapa é importante porque transforma o gráfico em storytelling: cada movimento relevante da série passa a ser conectado a um contexto econômico e político plausível.

Periodo	Comportamento	Contexto
2010-2015	Queda / estagnacao	Desaceleração econômica, deterioração fiscal e perda de confiança do mercado.
2015-2016	Ponto de minimo	Crise política, impeachment e recessão econômica elevaram a aversão a risco.
2016-2020	Ciclo de alta	Expectativa de reformas, juros globais baixos e retomada gradual do fluxo de risco.
Fev-Mar/2020	Choque abrupto	Pandemia de Covid-19, circuit breakers e repricing global de ativos.

2020-2021	Recuperacao em V	Estímulos monetários/fiscais e Selic em patamar historicamente baixo.
2021-2022	Lateralizacao / queda	Aperto monetário para conter inflação e aumento da incerteza eleitoral.
2023-2026	Novo ciclo de alta	Ciclo de corte de juros, resultados corporativos e renovação de recordes do índice.

Esse pano de fundo reforça que o IBOVESPA precisa ser reavaliado periodicamente: o comportamento estatístico do índice muda quando o ambiente de juros, risco político, fluxo estrangeiro e resultados corporativos também mudam.

3.2 Retornos, choques e faixa de tolerância

A variação diária mostra que a maior parte dos pregões se concentra em movimentos pequenos, enquanto choques extremos aparecem em momentos específicos, especialmente em 2020. Essa distribuição justifica usar uma métrica de tolerância além do WMAPE.




Figura 2 - Retornos diários e distribuição da variação percentual.

Faixa operacional

A média de variação absoluta média ficou próxima de 1,04%, enquanto o percentil 90 ficou perto de 2,20%. Por isso, a faixa de 2,15% foi usada como critério prático de acerto além do WMAPE.

4. Diagnóstico estatístico da série

4.1 Separação entre tendência, sazonalidade e resíduo

Para decompor a série em tendência, sazonalidade e resíduo, a série foi reorganizada em frequência diária e preenchida com o último fechamento conhecido apenas para fins visuais. Os modelos preditivos continuam usando os dias reais de pregão.




Figura 3 - Decomposição da série de fechamento.

A decomposição mostra que a tendência explica a maior parte do movimento histórico. A sazonalidade anual aparece com amplitude pequena, enquanto os resíduos concentram choques não explicados, principalmente em momentos de estresse de mercado.

4.2 Estacionariedade pelo teste ADF

O teste ADF foi usado para decidir a ordem de diferenciação do ARIMA. A hipótese nula do teste é que a série possui raiz unitária, ou seja, não é estacionária.

Teste ADF	P-valor	Interpretacao
Serie original	0,9506	Nao estacionaria
Primeira diferenca	0,00000000	Estacionaria

Como a série original não é estacionária e a primeira diferença se torna estacionária, a especificação integrada $d=1$ é tecnicamente justificada.

4.3 Memoria curta pela ACF e PACF




Figura 4 - ACF e PACF usadas como apoio para escolha do ARIMA.

Os gráficos de autocorrelação indicam dependência de curto prazo, sugerindo que os últimos pregões carregam informação relevante para a previsão do próximo fechamento. Essa leitura sustenta o teste de um ARIMA com componente autorregressivo curto.

5. Construção de alvos e atributos

Embora o ARIMA seja a entrega principal, também foram criados atributos técnicos para modelos supervisionados de comparação. Todos os atributos usam apenas informação disponível até o dia da previsão, evitando vazamento de dados.

- Retornos acumulados e defasados em janelas curtas.
- Médias móveis e distância do fechamento em relação às médias.
- Volatilidade recente, amplitude intradiária e corpo do candle.
- Posição do fechamento em janelas recentes.
- Indicadores técnicos como RSI, MACD e Bandas de Bollinger.
- Variáveis simples de calendário, como dia da semana e mês.

Indicador	Valor
Base com features	4.050 registros
Início da base modelável	2010-03-17
Fim da base modelável	2026-07-21
Proporcao historica de altas	51,21%

```
featured["fechamento_amanha"] = featured["fechamento"].shift(-1)
featured["alta_amanha"] = (
    featured["fechamento_amanha"] > featured["fechamento"]
).astype(int)

featured["retorno_5d"] = featured["fechamento"].pct_change(5)
featured["media_movel_21"] = featured["fechamento"].rolling(21).mean()
featured["volatilidade_21d"] = featured["retorno_1d"].rolling(21).std()
```

O ponto central dessa etapa é que o alvo sempre olha para o próximo pregão, enquanto as features olham apenas para trás. Essa separação reduz o risco de

lookahead bias e deixa a avaliação mais parecida com o uso real: ao final do dia D , o modelo tenta estimar $D+1$.

6. Validação fora da amostra

Para evitar vazamento de informação futura, a divisão entre treino e teste foi feita de forma temporal. A última observação da base limpa, 22/07/2026, é usada como fechamento conhecido como o alvo e o próximo pregão, o último alvo conhecido fica em 21/07/2026.

Conjunto	Registros	Período
Treino	3.979	2010-01-04 a 2026-01-19
Teste	125	2026-01-20 a 2026-07-21

```
def temporal_split(dataset, test_size=125):  
    train = dataset.iloc[:-test_size].copy()  
    test = dataset.iloc[-test_size:].copy()  
    return train, test
```

Validacao temporal

Não houve embaralhamento aleatório. O modelo foi treinado no passado e avaliado no período mais recente com alvo conhecido, simulando melhor uma situação real de previsão.

7. Experimentos e escolha do modelo

Foram comparados três caminhos: baseline de persistência, ARIMA estático e ARIMA walk-forward. A persistência usa o fechamento de hoje como previsto para amanhã; o ARIMA estático treina uma vez; o walk-forward recalibra o histórico a cada novo ponto observado no teste.

A função de avaliação concentra as métricas principais. O WMAPE foi escolhido por medir erro percentual ponderado pelo tamanho real da série; em seguida, a assertividade é calculada por $1 - \text{WMAPE}$, conforme orientação recebida para métricas de distância.

```
def wmape(y_true, y_pred):
    actual = np.asarray(y_true, dtype=float)
    predicted = np.asarray(y_pred, dtype=float)
    return np.sum(np.abs(actual - predicted)) / np.sum(np.abs(actual))

assertiveness = 1 - wmape(y_true, y_pred)
```

7.1 Referência ingênua: fechamento de hoje

O primeiro modelo testado foi o baseline Naive, ou persistência: a previsão para amanhã é simplesmente o fechamento de hoje. Em séries financeiras de alta liquidez, esse baseline costuma ser muito competitivo em erro percentual, justamente porque a variação diária tende a ser pequena.

```
naive_pred = test_reg["fechamento"].values
naive_result = evaluate_predictions(
    "Naive - persistencia",
    y_true,
    naive_pred,
)
```

Métrica do baseline	Resultado	Leitura
WMAPE	0,95%	Erro percentual ponderado muito baixo.
Assertividade	99,05%	Acima da meta, mas baseada em regra ingênua.
MAE	1.722 pontos	Erro médio absoluto em pontos do índice.
Acerto 2,15%	91,20%	Referencia operacional para comparar modelos.

Esse baseline não deve ser ignorado. Ele funciona como referência mínima: qualquer modelo mais sofisticado precisa ser comparado contra ele para que o resultado não pareça melhor do que realmente é. Ao mesmo tempo, ele não oferece estrutura estatística, intervalo de confiança nem explicação de comportamento da série; ele apenas repete o último fechamento conhecido.

7.2 Racional estatístico para o ARIMA

A escolha do ARIMA não foi feita apenas por tentativa e erro. O teste ADF mostrou que a série original não é estacionária, enquanto a primeira diferença se torna estacionária. Isso sustenta o termo integrado $d=1$. Os gráficos de ACF e PACF indicam dependência de curto prazo, coerente com uma especificação ARIMA simples e interpretável.

Vantagem	Por que importa neste projeto
Fundamentação estatística	A ordem do modelo é apoiada por ADF, ACF e PACF, tornando a decisão auditável.
Interpretabilidade	Os componentes autorregressivo e integrado são explicáveis para uma banca técnica.
Intervalo de confiança	A previsão traz faixas de incerteza, algo essencial em séries financeiras.
Baixo custo computacional	Funciona bem com uma única série histórica de cerca de 4 mil pregões.
Extensibilidade	Pode evoluir para SARIMAX com Selic, câmbio ou índices externos como variáveis exógenas.

7.3 Validacao walk-forward

Na avaliação walk-forward, o modelo é recalibrado a cada passo com o fechamento real observado no período de teste. Isso aproxima a avaliação de um uso prático: no fim de cada pregão, o histórico é atualizado e uma nova previsão é gerada.

```
history = list(train["fechamento"].values)
predictions = []
for actual_close in test["fechamento"].values:
    model = ARIMA(history, order=(5, 1, 0)).fit()
    predictions.append(float(model.forecast(steps=1)[0]))
    history.append(actual_close)
```

7.4 Resultado comparativo

Modelo	WMAPE	Assertividade	MAE	Acerto 2,15%
Naive - persistencia	0,95%	99,05%	1.722 pontos	91,20%
ARIMA(5,1,0) walk-forward	1,33%	98,67%	2.411 pontos	82,40%
ARIMA(5,1,0) estatico	8,84%	91,16%	15.979 pontos	2,40%




Figura 5 - Fechamento real versus previsões no período de teste.




Figura 6 - Erro percentual do ARIMA walk-forward ao longo do período de teste.

Modelo escolhido

O ARIMA(5,1,0) walk-forward foi escolhido para a narrativa principal por respeitar a estrutura temporal e atingir 98,67% de assertividade por 1 - WMAPE, além de 82,40% de acerto dentro da faixa de 2,15%.

7.5 Regressão com atributos técnicos

Como contraponto ao ARIMA, foram testados modelos de regressão supervisionada com os 37 atributos técnicos construídos na etapa de engenharia. A ideia foi verificar se sinais de retorno, volatilidade, médias móveis, candle, volume e calendário melhoraram a previsão do fechamento seguinte.

```
lin_reg = Pipeline([
    ("scaler", StandardScaler()),
    ("model", LinearRegression()),
])
lin_reg.fit(x_train, y_train)

rf_reg = RandomForestRegressor(
    n_estimators=300,
    max_depth=6,
    min_samples_leaf=10,
    random_state=42,
)
rf_reg.fit(x_train, y_train)
```

Modelo com atributos	WMAPE	Assertividade	MAE	Acerto 2,15%
Linear Regression - features	0,98%	99,02%	1.768 pontos	92,00%
Random Forest - features	10,22%	89,78%	18.487 pontos	0,00%

A regressão linear fica competitiva porque o próprio fechamento atual está entre as variáveis de entrada, fazendo o modelo aprender uma relação muito próxima da persistência. O Random Forest, por outro lado, perde aderência neste recorte porque modelos baseados em árvores tendem a criar faixas de previsão e podem ter dificuldade para extrapolar suavemente o nível atual do índice.

Por isso, os modelos com atributos entram como validação adicional, não como escolha final. Eles mostram que adicionar muitos indicadores técnicos não garante ganho real sobre uma série financeira de curto prazo. O ARIMA walk-forward permanece como modelo principal por ser mais aderente ao enunciado de séries temporais, ter fundamentação estatística pela estacionariedade/autocorrelação e entregar intervalo de confiança para a previsão de 15 pregões.




Figura 7 - Comparacao entre ARIMA, baseline e regressoes com atributos pela tolerancia de 2,15%.

7.6 Robustez da tolerância de erro

Como a leitura de acerto por tolerância depende da margem escolhida, também foi feita uma análise de sensibilidade. Isso evita escolher uma única faixa sem contexto e mostra como o modelo se comporta em margens mais conservadoras e mais flexíveis.

Tolerancia de erro	Acerto ARIMA walk-forward
1,00%	43,20%
1,50%	61,60%
2,00%	79,20%
2,15%	82,40%
2,50%	87,20%
3,00%	91,20%




Figura 8 - Distribuição do erro percentual absoluto do ARIMA walk-forward.




Figura 9 - Sensibilidade do acerto conforme a tolerancia de erro.

8. Investigação complementar de direção

Também foram testados modelos supervisionados com features técnicas e classificação de direção. Essa frente foi mantida como complemento, pois a orientação atual da prova favorece regressão e métricas de distância. A classificação de alta/baixa é naturalmente mais instável, especialmente em dias com variações pequenas.

Essa decisão deixa a entrega mais honesta. Em vez de inflar uma acurácia de direção por escolha oportunista de janela, threshold ou hiperparâmetro, o projeto reporta a regressão como resposta principal e a classificação como investigação dos limites do problema.

Leitura técnica

Prever o valor aproximado do fechamento é diferente de prever corretamente a direção diária. A segunda tarefa é mais dura e tende a ficar perto de 50% quando usamos apenas informações públicas do próprio índice.

9. Projeção dos próximos 15 pregões

Com a base atualizada até 22/07/2026, a previsão inicia em 23/07/2026 e termina em 12/08/2026. O intervalo de confiança aumenta ao longo do horizonte, refletindo a incerteza acumulada.

Data	Previsto	IC 95% inf.	IC 95% sup.
23/07/2026	175.648	173.246	178.050
24/07/2026	175.719	172.410	179.028
27/07/2026	175.709	171.653	179.766
28/07/2026	175.729	171.043	180.415
29/07/2026	175.782	170.533	181.032
30/07/2026	175.777	169.998	181.556
31/07/2026	175.780	169.517	182.042
03/08/2026	175.780	169.067	182.492
04/08/2026	175.781	168.647	182.914
05/08/2026	175.782	168.249	183.314
06/08/2026	175.781	167.871	183.692
07/08/2026	175.782	167.509	184.054
10/08/2026	175.782	167.163	184.400
11/08/2026	175.782	166.831	184.733
12/08/2026	175.782	166.510	185.053



Figura 10 - Projeção dos próximos 15 pregões.

10. Fechamento técnico

A solução final atende ao objetivo da prova substitutiva por tratar o IBOVESPA como série temporal, usar decomposição e estacionariedade para justificar o ARIMA, avaliar previsão numérica com WMAPE e apresentar uma previsão de 15 pregões com intervalo de confiança. O resultado principal supera a meta de 80% pela métrica de assertividade orientada por erro percentual.

10.1 Principais entregas

- Uma base histórica atualizada e limpa do IBOVESPA até 22/07/2026.
- Storytelling conectando ciclos do índice a eventos economicos relevantes.
- Decomposição, teste ADF e leitura de autocorrelação para justificar a abordagem temporal.
- Comparacao entre baseline, ARIMA estatico e ARIMA walk-forward.
- Previsão de 15 pregões com intervalo de confiança.

10.2 Limites da abordagem e evoluções

Uma assertividade alta por WMAPE não significa prever perfeitamente o mercado. O próprio baseline de persistência fica forte porque o IBOVESPA geralmente não muda muitos pontos de um pregão para o outro. Por isso, a entrega combina WMAPE, MAE, tolerância de erro e interpretação econômica, em vez de vender uma única métrica como verdade absoluta.

A classificação de direção diária segue mais difícil e instável, o que é coerente com a literatura de mercados eficientes. Como próximo passo, o projeto poderia evoluir para SARIMAX, incorporando variáveis exógenas como Selic, cambio, juros futuros, S&P 500, commodities e indicadores de sentimento.

A interpretação deve permanecer acadêmica e analítica: o modelo não substitui avaliação de risco, eventos macroeconômicos ou análise de mercado em tempo real.